Evaluación de estrategias de fusión de rangos —*rank fusion*— en la recuperación de información en español: un análisis sobre el conjunto de datos MessIRve

Jorge Esteban Mendoza Ortiz

1. Introducción

La recuperación de información (IR por sus siglas en inglés) constituye uno de los problemas fundamentales en la ciencia de datos y computación matemática modernas, siendo la base de sistemas críticos que van desde motores de búsqueda comerciales hasta los sistemas de Generación Aumentada por Recuperación (RAG por sus siglas en inglés). El problema de IR, como lo planteamos aquí, consiste en obtener un subconjunto relevante de documentos de un corpus más grande dada una consulta expresada en lenguaje natural. Históricamente este problema se ha abordado utilizando modelos probabilísticos y de coincidencia léxica, con el algoritmo BM25 estableciéndose actualmente como un estándar. No obstante, dado que estos modelos requieren coincidencia exacta entre los términos de las consultas y los documentos, a menudo fallan en capturar relaciones semánticas y contextuales. Esta limitación se acentúa en lenguas morfológicamente ricas como el español, en el que fenómenos como la flexión verbal, derivación y variaciones de género y número generan múltiples formas para un mismo lema, reduciendo la probabilidad de coincidencia exacta de términos.

El aprendizaje profundo y los modelos de lenguaje basados en la arquitectura *Transformer* han revolucionado el campo del procesamiento de lenguaje natural, introduciendo técnicas que permiten utilizar representaciones vectoriales del texto en las que la similitud semántica se cuantifica mediante distancias geométricas. A pesar del éxito de estos modelos —que conocemos como "semánticos"— en numerosas tareas, estos tienen sus propias limitaciones y fallas: tienden a perder precisión ante términos exactos o nombres propios poco frecuentes, áreas en las que los modelos léxicos tradicionales siguen siendo superiores. Esto sugiere que los modelos léxicos y semáticos no son sustitutos ni redundantes, sino complementarios.

En el contexto de la lengua española, la investigación en IR ha estado históricamente rezagada en comparación con su contraparte anglosajona. La reciente publicación del conjunto de datos MessIRve, con sus 700,000 consultas extraídas de intenciones de búsqueda reales a través de la API de autocompletado de Google, proporciona un marco de referencia estandarizado para evaluar modelos de recuperación en lengua española.

Aunque el estudio original estableció líneas base sólidas utilizando modelos semánticos y léxicos, comerciales y abiertos, existe una área de oportunidad poco explorada en la literatura en español: la fusión de rangos (*rank fusion*).

La presente tesis se centra, por tanto, en la aplicación y evaluación matemática de algoritmos de reordenamiento (*reranking*) que integran los resultados de sistemas de recuperación base léxicos y semánticos. La premisa central es que, mediante métodos de fusión de rangos como *Reciprocal Rank Fusion* (RRF), el Método de Borda o el Método de Condorcet, es posible mejorar la precisión del sistema final sin el costo computacional de entrenar nuevos modelos desde cero. Este trabajo investiga si la fusión de modelos *Open Source* puede igualar o superar los resultados reportados sobre el conjunto de datos MessIRve, ofreciendo una solución eficiente y accesible para la recuperación de información en español.

Haciendo uso de una metodología experimental cuantitativa, compararemos sistemas híbridos que usan algoritmos de fusión de rangos para combinar listas de candidatos generadas por modelos léxicos y semánticos, y utilizaremos métricas estándar —nDCG@10 y Recall@100— para analizar la efectividad de estas combinaciones y comparar los resultados obtenidos con los reportados en la literatura.

2. Objetivos

- **Objetivo general**

  Evaluar y comparar la eficacia de algoritmos de fusión de rangos (*Rank Fusion*) —específicamente métodos basados en puntuación (*Reciprocal Rank Fusion* y Método de Borda) y métodos basados en grafos (Condorcet)— aplicados a la combinación de resultados recuperados por modelos *Open Source* léxicos (BM25) y semánticos de vanguardia (*Dense/Sparse Embeddings*), utilizando el conjunto de datos MessIRve, con el fin de determinar si la hibridación mejora la relevancia en la recuperación de información en lengua española y si el desempeño de los modelos fusionados de código abierto puede igualar o superar al de modelos propietarios de referencia.

- **Objetivos Específicos**

  1. Fundamentar matemáticamente los métodos de representación vectorial (*Embeddings*, *Dual-Encoders*, *Cross-Encoders*, modelos híbridos y de interacción tardía), los modelos léxicos (BM25) y los algoritmos de fusión de rangos (*Reciprocal Rank Fusion*, Método de Borda y Método de Condorcet).
  2. Implementar un sistema de recuperación base utilizando herramientas y modelos *Open Source* léxicos y semánticos sobre el conjunto de datos MessIRve.
  3. Diseñar y ejecutar experimentos que evalúen la fusión de rangos combinando listas de candidatos generadas por los modelos individuales mediante tres

algoritmos: *Reciprocal Rank Fusion* (RRF), Método de Borda y Método de Condorcet.

4. Comparar el rendimiento de los métodos de Borda y Condorcet frente al estándar *Reciprocal Rank Fusion* para determinar si ofrecen un desempeño superior en la recuperación de información en lengua española.
5. Contrastar el rendimiento de los sistemas híbridos de fusión de rangos implementados con modelos *Open Source* frente a las líneas base de modelos propietarios (como `text-embedding-3-large` de OpenAI reportado en el *paper* de MessIRve) utilizando métricas estándar como $nDCG@10$ y $Recall@100$.
6. Analizar la complementariedad entre los modelos léxicos y semánticos en español e identificar en qué condiciones la fusión de rangos aporta mejoras significativas y en cuáles no.

3. Índice tentativo

1. Resumen
2. Introducción
   a) Motivación
   b) Objetivos
   c) Hipótesis
   d) Preguntas de investigación
   e) Contribución
   f) Organización de la tesis
3. Marco teórico
   a) Fundamentos de recuperación de información
   b) Modelos de recuperación
      1) Modelos léxicos
      2) Modelos basados en *embeddings*
         a′ *Dual–encoders*
         b′ *Cross–encoders*
         c′ Modelos híbridos
         d′ Modelos de interacción tardía
   c) Fundamentos de la fusión de rangos
   d) Evaluación en recuperación de información
   e) Estructura de *benchmarks* para *IR*

f) Entrenamiento y adaptación de modelos

g) Resumen

4. Estado del arte

   a) Modelos de recuperación

      1) Modelos léxicos

      2) Modelos basados en *embeddings*

         a′ *Dual–encoders*

         b′ *Cross–encoders*

         c′ Modelos híbridos

         d′ Modelos de interacción tardía

      3) *Modelos de interacción tardía*

   b) Estrategias de *reranking* y fusión

   c) *Benchmarks* para *IR* multilingües

   d) *IR* en español

      1) *Benchmarks* para *IR* en español

      2) Problemas específicos del español

5. Metodología propuesta

   a) El conjunto de datos MessIRve

   b) Arquitectura del sistema de recuperación

   c) Modelos de recuperación base

   d) Algoritmos de fusión

   e) Diseño experimental

      1) Experimento 1: fusión *vs.* modelos individuales

      2) Experimento 2: comparación de algoritmos de fusión

      3) Experimento 3: modelos abiertos *vs.* propietarios

6. Resultados experimentales

7. Conclusiones y trabajo futuro

8. Bibliografía

9. Apéndices

Referencias

Aslam, Javed A. y Mark Montague (2001). «Models for metasearch». En: *Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR '01. New Orleans, Louisiana, USA: Association for Computing Machinery, págs. 276-284. ISBN: 1581133316. DOI: 10.1145/383952.384007. URL: https://doi.org/10.1145/383952.384007.

Bassani, Elias y Luca Romelli (2022). «ranx.fuse: A Python Library for Metasearch». En: *Proceedings of the 31st ACM International Conference on Information & Knowledge Management*. CIKM '22. Atlanta, GA, USA: Association for Computing Machinery, págs. 4808-4812. ISBN: 9781450392365. DOI: 10.1145/3511808.3557207. URL: https://doi.org/10.1145/3511808.3557207.

Chen, Jianlyu et al. (ago. de 2024). «BGE M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation». En: *Findings of the Association for Computational Linguistics: ACL 2024*. Ed. por Lun-Wei Ku, Andre Martins y Vivek Srikumar. Bangkok, Thailand: Association for Computational Linguistics, págs. 2318-2335. DOI: 10.18653/v1/2024.findings-acl.137. URL: https://aclanthology.org/2024.findings-acl.137/.

Cormack, Gordon V., Charles L A Clarke y Stefan Buettcher (2009). «Reciprocal rank fusion outperforms condorcet and individual rank learning methods». En: *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR '09. Boston, MA, USA: Association for Computing Machinery, págs. 758-759. ISBN: 9781605584836. DOI: 10.1145/1571941.1572114. URL: https://doi.org/10.1145/1571941.1572114.

Formal, Thibault, Benjamin Piwowarski y Stéphane Clinchant (2021). «SPLADE: Sparse Lexical and Expansion Model for First Stage Ranking». En: *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR '21. Virtual Event, Canada: Association for Computing Machinery, págs. 2288-2292. ISBN: 9781450380379. DOI: 10.1145/3404835.3463098. URL: https://doi.org/10.1145/3404835.3463098.

Grandury, María et al. (jul. de 2025). «La Leaderboard: A Large Language Model Leaderboard for Spanish Varieties and Languages of Spain and Latin America». En: *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Ed. por Wanxiang Che et al. Vienna, Austria: Association for Computational Linguistics, págs. 32482-32524. ISBN: 979-8-89176-251-0. DOI: 10.18653/v1/2025.acl-long.1561. URL: https://aclanthology.org/2025.acl-long.1561/.

Jha, Rohan et al. (nov. de 2024). «Jina-ColBERT-v2: A General-Purpose Multilingual Late Interaction Retriever». En: *Proceedings of the Fourth Workshop on Multilingual Representation Learning (MRL 2024)*. Ed. por Jonne Sälevä y Abraham Owodunni. Miami, Florida, USA: Association for Computational Linguistics, págs. 159-166. DOI: 10.18653/v1/2024.mrl-1.11. URL: https://aclanthology.org/2024.mrl-1.11/.

Khattab, Omar y Matei Zaharia (2020). «ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT». En: *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR '20. Virtual Event, China: Association for Computing Machinery, págs. 39-48. ISBN: 9781450380164. DOI: 10.1145/3397271.3401075. URL: https://doi.org/10.1145/3397271.3401075.

Lassance, Carlos et al. (2024). *SPLADE-v3: New baselines for SPLADE*. arXiv: 2403.06789 [cs.IR]. URL: https://arxiv.org/abs/2403.06789.

Lin, Jimmy et al. (2021). «Pyserini: A Python Toolkit for Reproducible Information Retrieval Research with Sparse and Dense Representations». En: *Proceedings of the 44th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2021)*, págs. 2356-2362.

Liu, Zheng et al. (2025). *Llama2Vec: Unsupervised Adaptation of Large Language Models for Dense Retrieval*. arXiv: 2312.15503 [cs.CL]. URL: https://arxiv.org/abs/2312.15503.

Montague, Mark y Javed A. Aslam (2002). «Condorcet fusion for improved retrieval». En: *Proceedings of the Eleventh International Conference on Information and Knowledge Management*. CIKM '02. McLean, Virginia, USA: Association for Computing Machinery, págs. 538-548. ISBN: 1581134924. DOI: 10.1145/584792.584881. URL: https://doi.org/10.1145/584792.584881.

Reimers, Nils e Iryna Gurevych (nov. de 2019). «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». En: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics. URL: https://arxiv.org/abs/1908.10084.

Robertson, Stephen y Hugo Zaragoza (abr. de 2009). «The Probabilistic Relevance Framework: BM25 and Beyond». En: *Found. Trends Inf. Retr.* 3.4, págs. 333-389. ISSN: 1554-0669. DOI: 10.1561/1500000019. URL: https://doi.org/10.1561/1500000019.

Valentini, Francisco et al. (nov. de 2025). «MessIRve: A Large-Scale Spanish Information Retrieval Dataset». En: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*. Ed. por Christos Christodoulopoulos et al. Suzhou, China: Association for Computational Linguistics, págs. 27752-27769. ISBN: 979-8-89176-332-6. DOI: 10.18653/v1/2025.emnlp-main.1412. URL: https://aclanthology.org/2025.emnlp-main.1412/.

Wang, Feng, Yuqing Li y Han Xiao (2025). *jina-reranker-v3: Last but Not Late Interaction for Listwise Document Reranking*. arXiv: 2509.25085 [cs.CL]. URL: https://arxiv.org/abs/2509.25085.

Wang, Liang et al. (2024). *Multilingual E5 Text Embeddings: A Technical Report*. arXiv: 2402.05672 [cs.CL]. URL: https://arxiv.org/abs/2402.05672.

Zhang, Yanzhao et al. (2025). *Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models*. arXiv: 2506.05176 [cs.CL]. URL: https://arxiv.org/abs/2506.05176.

Vo. Bo.

Firma del Alumno: _____

Jorge Esteban Mendoza Ortiz

Directora de tesis: _____

Dra. Helena Gómez Adorno

Investigadora Titular A

IIMAS-UNAM